Práctica 10

Análisis distribuido de mantenimiento en una flota robótica industrial

Jordi Blasco Lozano
Computación de alto rendimiento
Grado en Inteligencia Artificial

Índice:

1. Introducción

Hemos montado un mini laboratorio para procesar los logs de varios brazos robóticos de forma rápida y paralela. La idea clave es:

1. Leer muchos ficheros de texto que contienen sucesos técnicos (sobrecalentamientos, reinicios, calibraciones, etc.).
2. Filtrar solo los eventos que nos interesan.
3. Contar cuántas veces aparece cada tipo de evento.
4. Mostrar un pequeño informe con las cuentas.

Para hacerlo usamos Apache Spark con Scala ya que:

- Spark divide los datos en particiones y ejecuta operaciones filter, map, reduceByKey al mismo tiempo en cada trozo, aprovechando todos los núcleos de la máquina.
- Hasta que no pedimos el resultado final con collect(), Spark solo construye el plan de trabajo; al llamar a collect() se dispara todo el procesamiento, se unen los resultados y se devuelven al programa principal.
- Scala encaja muy bien con Spark: su sintaxis funcional y tipada nos permite escribir las cadenas de transformación de forma muy clara y compacta.

2. Desarrollo

Para simplificar la puesta en marcha y evitar tener que invocar manualmente spark-shell con múltiples flags, hemos definido un Dockerfile que contiene la imagen oficial de Bitnami Spark y copia en /app todo nuestro proyecto (scripts Scala y carpeta registros).

practica10 - DOCKERFILE

```
FROM bitnami/spark:latest

# 1) Nos aseguramos de usar el usuario root (para poder crear ~/.ivy2)
USER root

# 2) Creamos el HOME y el dir de ivy
ENV HOME=/root
RUN mkdir -p /root/.ivy2/local

# 3) Copiamos todo el proyecto a /app
WORKDIR /app
COPY . /app

# 4) Arrancamos spark-shell en modo local[*] con UI en 4040
ENTRYPOINT ["spark-shell", \
            "--master", "local[*]", \
            "--conf", "spark.ui.port=4040" \
           ]
```

Este Dockerfile:

- Establece un HOME válido y crea ~/.ivy2/local para que Ivy no falle al gestionar dependencias.
- Copia el código y los datos a /app.
- Fija como ENTRYPOINT el comando: spark-shell --master local[*] --conf spark.ui.port=4040

De este modo, basta con ejecutar:

practica10 - shell.txt

```
docker build -t practica10-spark .
docker run -it --rm -p 4040:4040 practica10-spark
```

Automáticamente tendremos primero los logs de la ejecución de spark y finalmente una shell con scala para poder cargar archivos .scala que tengamos en nuestro contenedor o directamente ejecutar los comandos en terminal. Para esta práctica hemos optado por la estructura sugerida. Tendremos un archivo spark-shell.scala que se cargará en la terminal con el comando :load /app/spark-shell.scala.
La carga de este archivo ejecuta las siguientes operaciones definidas en él:

1. **Importación**: Se importa org.apache.spark.SparkContext._ para habilitar las transformaciones y acciones sobre RDDs, como reduceByKey.

2. **Lectura de datos**: Se utiliza sc.textFile("/app/registros/*.txt") para leer todos los archivos .txt presentes en la carpeta /app/registros (montada desde la carpeta local registros/) y crear un RDD de strings llamado registros, donde cada elemento es una línea de un archivo de log.

3. **Definición de eventos clave**: Se crea un Set[String] llamado eventosClave que contiene los identificadores de los eventos que se desean rastrear.

4. **Filtrado y Mapeo flatMap**: Se aplica una transformación flatMap sobre el RDD registros. Esta operación:
   - Divide cada línea usando " - " como separador.
   - Comprueba si la división produjo al menos dos partes (parts.length >= 2) y si la segunda parte (parts(1)) está contenida en el conjunto eventosClave.
   - Si ambas condiciones son ciertas, emite una tupla (evento, 1).
   - Si alguna condición falla (línea mal formada o evento no clave), no emite nada (None), descartando esa línea de forma segura y evitando errores ArrayIndexOutOfBoundsException. El resultado es un nuevo RDD llamado pares de tipo RDD[(String, Int)].

5. **Reducción (reduceByKey):** Se aplica reduceByKey(_ + _) sobre el RDD pares. Esta operación agrupa todas las tuplas por su clave (el nombre del evento) y suma sus valores, generando un RDD llamado conteos que contiene pares (evento, total_ocurrencias).

6. **Recolección (collect):** Se ejecuta la acción conteos.collect(). Esta acción desencadena la ejecución de todas las transformaciones anteriores (lectura, flatMap, reduceByKey) en el clúster Spark (en este caso, localmente). El resultado final, que es un Array[(String, Int)] con el conteo total de cada evento clave, se envía de vuelta al programa driver (el spark-shell) y se almacena en la variable resultado.

7. **Impresión:** Finalmente, se itera sobre el array resultado usando foreach y se imprime cada par (evento, conteo) formateado en la consola.

Una vez que el comando :load /app/spark-shell.scala ha terminado de ejecutarse en el REPL, la variable resultado ya contiene el array con los conteos finales y está disponible en el scope de la sesión de spark-shell. Para volver a ver o trabajar con estos resultados, simplemente se puede escribir resultado en el shell y presionar Enter:

Código

```
import org.apache.spark.SparkContext._

// 1) Leer todos los logs
val registros = sc.textFile("/app/registros/*.txt")

// 2) Definir eventos clave
val eventosClave = Set(
  "ALERTA_SOBRECALENTAMIENTO",
  "REINICIO_SISTEMA",
  "CALIBRACION_AUTOMATICA",
  "CARGA_EXCESIVA",
  "PAUSA_NO_PROGRAMADA"
)

// 3) Filtra, parsea y mapea a pares (String,Int)
val pares = registros.flatMap { line =>
  val parts = line.split(" - ")
  if (parts.length >= 2 && eventosClave.contains(parts(1)))
    Some((parts(1), 1))
  else
    None
}

// 4) Reduce por clave
val conteos = pares.reduceByKey(_ + _)

// 5) Traer al driver y mostrar
val resultado = conteos.collect()
println("Conteo de eventos:")
resultado.foreach{ case (ev, cnt) =>
  println(f"$ev%-25s $cnt%5d")
}
```

Ejecución

Terminal

practica10 - shell.txt

```
scala> :load /app/spark-shell.scala
Loading /app/spark-shell.scala...
import org.apache.spark.SparkContext._
registros: org.apache.spark.rdd.RDD[String] = /app/registros/*.txt MapPartitionsRDD[1] at textFile at /app/spark-shell.scala:26
eventosClave: scala.collection.immutable.Set[String] = Set(PAUSA_NO_PROGRAMADA, REINICIO_SISTEMA, CALIBRACION_AUTOMATICA, ALERTA_SOBRECALENTAMIENTO, CARGA_EXCESIVA)
pares: org.apache.spark.rdd.RDD[(String, Int)] = MapPartitionsRDD[2] at flatMap at /app/spark-shell.scala:27
conteos: org.apache.spark.rdd.RDD[(String, Int)] = ShuffledRDD[3] at reduceByKey at /app/spark-shell.scala:26
resultado: Array[(String, Int)] = Array((ALERTA_SOBRECALENTAMIENTO,92), (CALIBRACION_AUTOMATICA,70), (PAUSA_NO_PROGRAMADA,71), (CARGA_EXCESIVA,79), (REINICIO_SISTEMA,88))
Conteo de eventos:
ALERTA_SOBRECALENTAMIENTO    92
CALIBRACION_AUTOMATICA       70
PAUSA_NO_PROGRAMADA          71
CARGA_EXCESIVA               79
REINICIO_SISTEMA             88

# posteriormente podemos escribir
scala> resultado.foreach(println)
(ALERTA_SOBRECALENTAMIENTO,92)
(CALIBRACION_AUTOMATICA,70)
(PAUSA_NO_PROGRAMADA,71)
(CARGA_EXCESIVA,79)
(REINICIO_SISTEMA,88)
```

Pestaña Jobs

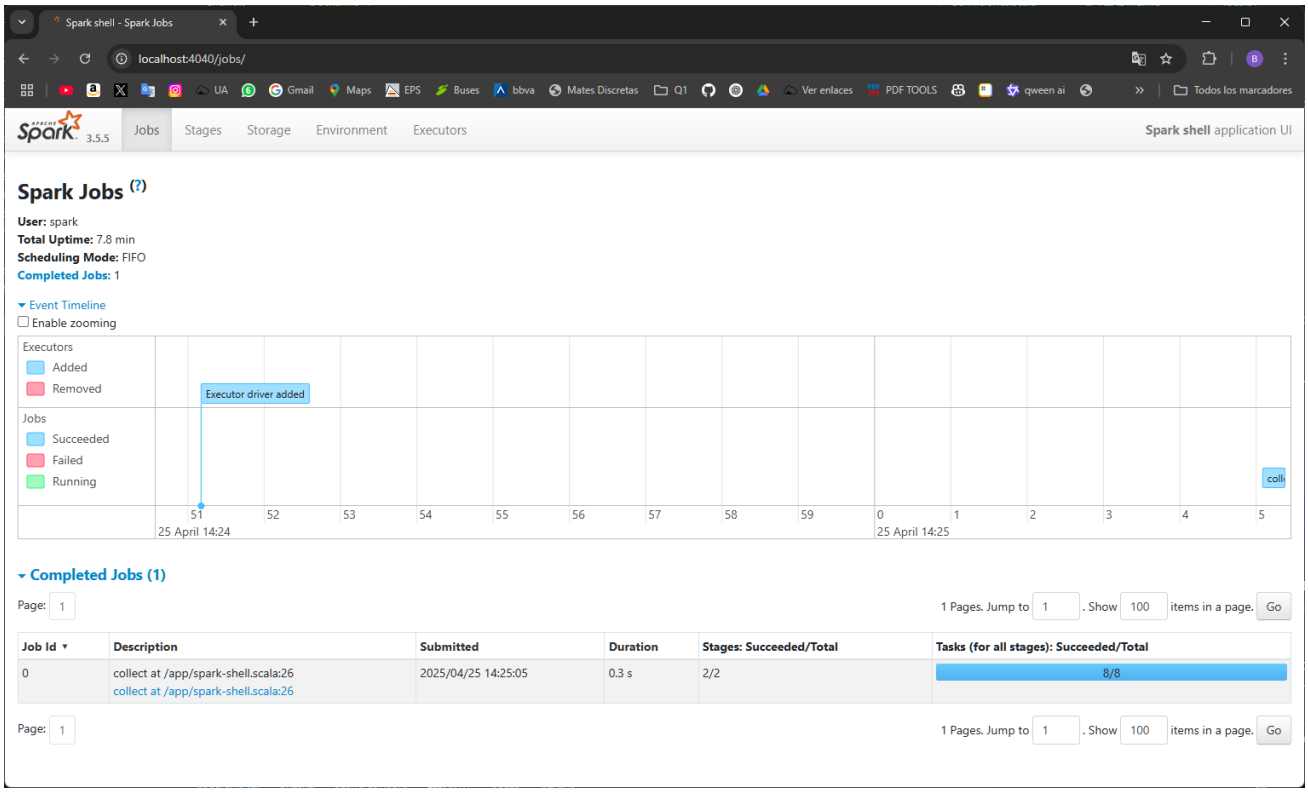

Datails del Job ejecutado (incluyendo stages)

Es la misma pestaña que `Stages` pero con más datos sobre el Job, contiene las mismas Stages que la pestaña `Stages` al solo haber ejecutado un único Job.

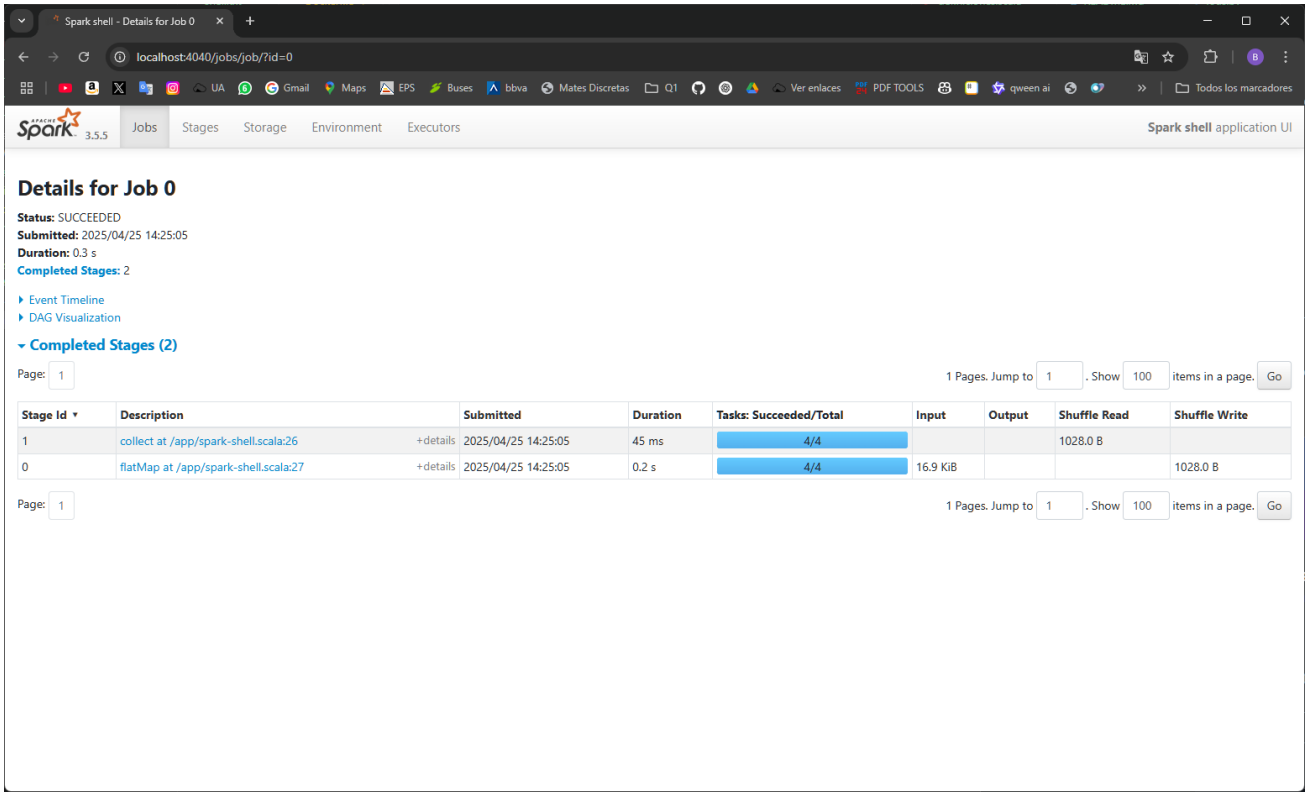

Pestaña Executors

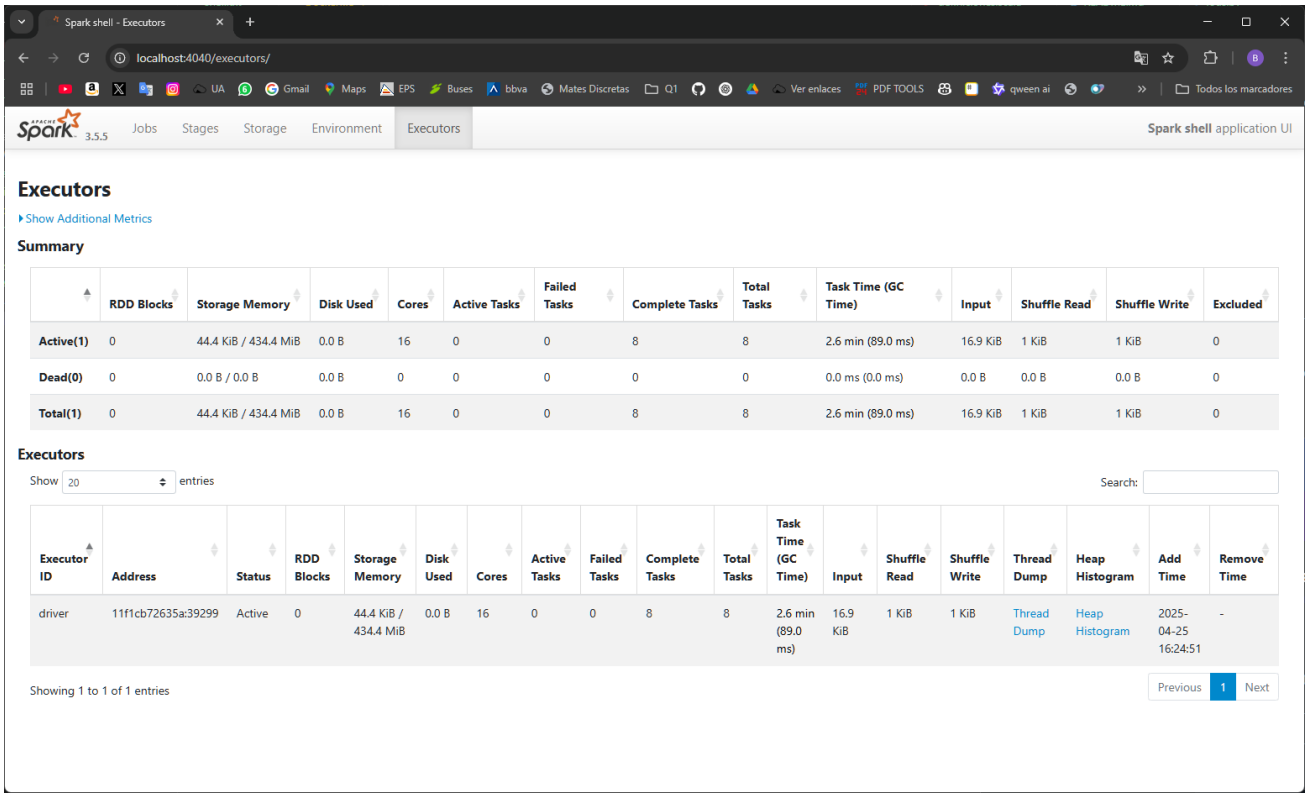

Conclusiones sobre la ejecución.

Al ejecutar :load /app/spark-shell.scala, la acción final conteos.collect() dispara un Job en Spark.

La Pestaña Jobs (y Details del Job) muestra que Spark dividió este Job en 2 Stages debido a la operación reduceByKey, que requiere un shuffle (redistribución de datos):

- Stage 0: Corresponde a la lectura de los archivos (textFile) y la transformación flatMap. Spark lee los datos de entrada, filtra las líneas y mapea los eventos clave a pares (evento, 1). El resultado de esta etapa son datos intermedios que se escriben para el shuffle.
- Stage 1: Corresponde a la operación reduceByKey y la acción collect. Spark lee los datos intermedios de la etapa anterior, agrupa los pares por evento, suma los conteos, y finalmente envía el array resultante (resultado) al driver (la terminal).

La Pestaña Executors confirma que todo el trabajo se realizó en el driver al ejecutarse en modo local[*].