



Universitat d'Alacant
Universidad de Alicante

Ejemplo comentado de resolución – IA urbana con HPC (plantilla)

Problema elegido: Gestión predictiva del consumo eléctrico en barrios urbanos

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Índice

Bloque 1: Introducción y análisis del reto urbano

- Contexto de la IA urbana y la HPC
- Descripción del problema elegido
- Primeras decisiones de diseño
- Dilemas éticos iniciales

Bloque 2: Tipos de datos y decisiones sobre su obtención

- Qué datos se necesitan y por qué
- Cómo se obtienen
- Problemas de privacidad y calidad
- Alternativas y justificación

Bloque 3: Elección del modelo de IA

- Comparativa entre modelos (LSTM, XGBoost, etc.)
- Justificación técnica y ética
- Diseño del modelo propuesto
- Opciones desechadas y por qué

Bloque 4: Infraestructura HPC y sostenibilidad del sistema

- Cómputo requerido
- Opciones sostenibles
- Alineación con principios de eficiencia energética
- Comentarios sobre escalabilidad

Bloque 5: Estimaciones energéticas y comparación con alternativa ligera

- Cálculo detallado de consumo y emisiones
- Comparativa de modelos
- Compromisos y decisiones realistas

Bloque 6: Reflexión ética y profesional

- Equidad, explicabilidad y sostenibilidad
- Decisiones clave justificadas
- Lo que se ganaría/perdería cambiando decisiones

Bloque 7: Comentarios como plantilla

- Frases modelo
- Notas orientadoras para otros retos
- Alternativas para tráfico, residuos u otros



Universitat d'Alacant
Universidad de Alicante

Bloque 1: Introducción y análisis del reto urbano

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



1.1. Contexto general

En las ciudades modernas, la gestión eficiente del consumo eléctrico es uno de los principales retos urbanos. La demanda energética varía en función de múltiples factores como la hora del día, el clima, los hábitos sociales o la movilidad de la población. Si no se gestiona adecuadamente, pueden producirse sobrecargas, apagones o infrautilización de la red.

La IA, combinada con computación de alto rendimiento (HPC), permite anticipar estos patrones y diseñar estrategias de reparto de carga más eficientes.

Frase modelo:

“He elegido el problema del consumo eléctrico urbano porque permite aplicar modelos predictivos que mejoran la sostenibilidad del sistema eléctrico y requieren infraestructura HPC para manejar la complejidad y el volumen de datos.”

1.2. Justificación del reto elegido

Este reto es adecuado para practicar con HPC porque:

Se basa en grandes volúmenes de datos de sensores y redes eléctricas.

Requiere modelos de IA con capacidad para aprender secuencias temporales.

Implica decisiones éticas sobre privacidad y discriminación de zonas.

Tiene impacto social y ambiental directo.

Además, está alineado con los contenidos explicados en clase sobre **Big Data**, **escalabilidad** y **sostenibilidad energética**.

Nota para el estudiante:

Si eliges otro problema urbano (por ejemplo, tráfico o gestión de residuos), asegúrate de justificar también por qué es adecuado para aplicar IA + HPC. ¿Qué datos genera? ¿Qué decisiones permitiría automatizar? ¿Qué impacto tiene?

1.3. Primeros dilemas técnicos y éticos

Desde el inicio del diseño surgen preguntas clave:

¿Qué tipo de datos necesitamos y cómo los conseguimos?

¿Cómo podemos usar datos de consumo sin invadir la privacidad de los hogares?

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



¿Qué nivel de detalle es útil sin ser excesivo (ej. por hogar, por barrio, por calle)?

¿Tendremos los mismos datos en todos los barrios o zonas? Si no, ¿puede haber sesgos?

Reflexión guía para el alumno:

Todo proyecto de IA urbana parte de un equilibrio entre precisión técnica, coste computacional, y responsabilidad ética. Anota desde el principio qué riesgos ves, y qué valores quieres priorizar en tu diseño.

1.4. Primeras decisiones tomadas en este ejemplo

En este caso, hemos decidido:

Trabajar a nivel de **barrios urbanos**, no por hogar individual (por motivos éticos y prácticos).

Usar datos históricos de consumo, combinados con información meteorológica y de movilidad.

Garantizar que todos los datos estén anonimizados y sean agregados.

Proponer un sistema distribuido que pueda reentrenarse de forma periódica para adaptarse a cambios de hábitos o eventos extraordinarios.

Frase modelo adaptativa:

“Para este reto, he decidido trabajar a nivel de [zona o unidad urbana] y usar datos de [fuentes específicas], priorizando la privacidad y buscando una solución replicable y escalable.”

1.5. Nota de uso como plantilla

Este bloque sirve como modelo para cualquier otro reto urbano propuesto. Si el estudiante escoge otro tema, debe:

Explicar por qué es un problema relevante y actual.

Relacionarlo con los conceptos de IA + HPC explicados en clase.

Identificar los dilemas técnicos y sociales que plantea.

Tomar decisiones iniciales justificadas, no solo técnicas, también éticas.

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Bloque 2: Tipos de datos y decisiones sobre su obtención

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



2.1. ¿Qué datos necesita este sistema?

Para predecir el consumo eléctrico de un barrio con anticipación suficiente (por ejemplo, 24 horas), el sistema debe disponer de información con alto valor predictivo. En este caso, hemos identificado como imprescindibles los siguientes tipos de datos:

Consumo eléctrico horario por zona: datos de consumo agregados por fase eléctrica y por código postal o barrio.

Histórico de consumo: al menos 2–3 años de registros anteriores para entrenar modelos con estacionalidad y patrones horarios.

Datos meteorológicos: temperatura, humedad, nubosidad, viento (afectan el uso de climatización).

Datos de movilidad: concentración de personas en cada zona, eventos, días festivos o teletrabajo masivo.

Frase modelo para estudiantes:

“Para poder hacer predicciones fiables en el problema de [nombre del reto], necesito datos sobre [tipo de datos 1], [tipo 2] y [tipo 3], porque influyen directamente en el comportamiento que quiero anticipar.”

2.2. ¿De dónde se obtienen estos datos?

Una parte clave del diseño es decidir **cómo se accede a estos datos** de forma legal, técnica y ética. En este caso:

Datos de consumo: suministrados por compañías eléctricas bajo acuerdos de colaboración (nivel agregado, sin datos personales).

Datos meteorológicos: disponibles vía APIs públicas (ej. AEMET, OpenWeather).

Datos de movilidad: sensores urbanos, datos anonimizados de telefonía móvil o de plataformas municipales de Smart City.

Fechas especiales: se pueden incorporar manualmente o a través de calendarios abiertos (festivos, eventos locales).

Nota ética clave:

Nunca se deben usar datos de consumo o movilidad a nivel individual sin consentimiento explícito, ni almacenar identificadores personales.

2.3. Alternativas de datos y decisiones

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



En este punto, hay que tomar decisiones estratégicas:

¿Se trabaja con datos de todos los barrios por igual o se seleccionan zonas piloto?

¿Se agregan los datos por hora, por franja horaria o por día?

¿Se incluyen solo los datos eléctricos o también otras fuentes contextuales (sociales, económicas)?

Reflexión para el alumno:

Cuanto más detallado el dato, más potente el modelo, pero también mayor el coste computacional y mayor el riesgo ético. ¿Dónde trazas la línea?

Frase modelo reflexiva:

“He decidido limitar los datos a [lista] para reducir el riesgo de sobreajuste y garantizar la privacidad. Aunque se pierde precisión, se gana en sostenibilidad y replicabilidad.”

2.4. Riesgos asociados y medidas preventivas

Los principales riesgos que detectamos son:

Riesgo	Medida de prevención
Uso excesivo de datos personales	Anonimización y agregación antes del análisis
Datos desiguales entre barrios (sesgo estructural)	Validación por zona y balanceo de muestras
Datos erróneos o incompletos	Limpieza previa y sistema de verificación
Dependencia de fuentes externas (APIs)	Redundancia con fuentes alternativas

Comentario para el estudiante:

Cuando diseñes tu sistema, dedica un apartado a explicar los riesgos y cómo los evitarás. Esta parte muestra responsabilidad profesional.

2.5. Nota de uso como plantilla

Este bloque se puede usar en cualquier otro reto urbano. Para adaptarlo, el estudiante debe:

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Identificar **qué variables** explican el fenómeno que quiere predecir.

Justificar la **selección de fuentes** (disponibilidad, coste, fiabilidad).

Mostrar **preocupación por el equilibrio** entre precisión, privacidad y sostenibilidad.

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Bloque 3: Elección del modelo de IA

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



3.1. ¿Qué tipo de modelo se necesita en este reto?

En este problema queremos anticipar el **consumo eléctrico futuro** de un barrio urbano. Es decir, **predecir lo que va a ocurrir basándonos en lo que ha ocurrido antes**. Técnicamente, esto se llama un **problema de series temporales**, aunque no necesitas dominar ese concepto para poder abordarlo.

¿Qué es una serie temporal?

Una *serie temporal* es simplemente un conjunto de datos ordenados en el tiempo. Por ejemplo:

Consumo eléctrico cada hora.

Temperatura diaria.

Número de personas en una zona cada 10 minutos.

En este caso, usamos ese historial de datos para que una IA aprenda **patrones repetitivos o tendencias**. Por ejemplo:

Que el consumo suele subir a las 8:00 y a las 20:00.

Que en invierno se consume más electricidad.

Que en días festivos la demanda baja.

A esto lo llamamos **patrones cíclicos o estacionales**. El modelo debe ser capaz de detectarlos y anticiparlos.

Además, queremos tener en cuenta **factores externos** como:

El clima (si hace calor, se encienden más aires acondicionados).

La movilidad (si hay conciertos o eventos, sube el consumo).

Festivos, teletrabajo, etc.

Frase modelo para estudiantes:

“Este es un problema donde la variable principal cambia con el tiempo, así que necesito un modelo capaz de detectar patrones horarios, semanales y estacionales. Además, quiero que el modelo tenga en cuenta otras variables como el clima o los eventos.”

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



3.2. ¿Qué modelos puedo usar y por qué elegir uno u otro?

Existen muchos tipos de modelos de IA o estadísticos. Aquí comparamos los más conocidos con sus ventajas e inconvenientes:

Modelo	Ventajas principales	Limitaciones o riesgos
ARIMA	Sencillo, interpretable, ideal si solo tienes una variable	No maneja bien datos externos ni cambios bruscos
Random Forest	Rápido, útil con datos variados	No es específico para secuencias temporales
XGBoost	Muy preciso en muchos problemas	Requiere transformar los datos para detectar ciclos
LSTM	Especial para series temporales y multivariantes	Más difícil de entrenar, menos transparente

En este caso, **elegimos LSTM** porque:

Es capaz de aprender patrones repetitivos (horarios, semanales...).

Acepta múltiples variables como entrada (clima, movilidad...).

Funciona bien con datos históricos largos.

Frase modelo justificativa:

“He elegido LSTM porque es un modelo capaz de aprender patrones en los datos temporales y usar múltiples fuentes de información al mismo tiempo.”

3.3. Si elijo otro modelo, ¿qué tengo que tener en cuenta?

Si decides usar otro modelo para tu reto (por ejemplo, si tratas de predecir atascos, niveles de ruido o recogida de basuras), debes justificar tu elección respondiendo:

¿Qué tipo de problema tienes? ¿Predicción numérica? ¿Clasificación de categorías? ¿Agrupamiento?

¿Tu modelo puede aprender patrones a lo largo del tiempo? Si no, ¿puedes adaptar los datos para que lo haga?

¿Qué variables vas a usar? ¿Tu modelo las puede combinar bien?

¿Es sostenible entrenar ese modelo para tu caso? ¿Tiene un consumo computacional razonable?

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Frase modelo para otros retos:

“He optado por usar un modelo [nombre] porque mi problema no requiere detectar secuencias temporales, sino clasificar [caso]. He preferido un modelo más ligero y explicable.”

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Bloque 4: Infraestructura HPC y sostenibilidad del sistema

Ejemplo comentado – Gestión predictiva del consumo eléctrico

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



4.1. ¿Qué recursos de computación hacen falta?

Una vez elegido el modelo, debemos pensar:

- ¿Dónde y cómo se va a entrenar este modelo?
- ¿Qué capacidad de cálculo y almacenamiento vamos a necesitar?

En nuestro caso, entrenar una red neuronal LSTM con varios años de datos por barrio y múltiples variables puede ser **costoso en términos de procesamiento y tiempo**. Es decir, **no se puede hacer en un portátil normal de forma eficiente**.

Por eso necesitamos una infraestructura de computación de alto rendimiento (HPC), aunque sea de nivel medio.

4.2. Opciones de infraestructura posibles

Opción	Ventajas	Inconvenientes
Clúster local (universidad)	Control total, datos seguros	Mantenimiento, disponibilidad limitada
Servidor potente (GPU)	Ideal para modelos LSTM	Coste elevado, puede ser infrautilizado
Plataforma cloud HPC (Azure, Google)	Escalable, pago por uso	Dependencia externa, huella de carbono elevada
Entrenamiento distribuido	Divide el entrenamiento entre varios nodos	Necesita conocimientos de paralelismo o middleware

Frase modelo:

“He decidido entrenar el modelo en un entorno con acceso a GPU, ya que este tipo de red neuronal necesita operaciones matriciales intensivas que se aceleran con este hardware.”



4.3. Coste energético y sostenibilidad

Como hemos visto en clase, los superordenadores modernos como **Frontier** o los centros de datos que entrenan IA (como GPT-4) consumen cantidades enormes de electricidad.

Por tanto, en este ejercicio también debemos **reflexionar sobre el impacto ambiental** de nuestras decisiones.

Supongamos que entrenar el modelo consume:

4 horas en una GPU estándar (300W) = 1,2 kWh

Si se entrena 10 veces para ajustar parámetros = **12 kWh**

Eso equivale aproximadamente a 2 días de consumo de un frigorífico eficiente, o a 10 cargas de lavadora

Puede parecer poco, pero si esto se multiplica por 50 barrios, por 10 versiones del modelo, y se repite cada semana... el impacto crece.

Comentario ético:

“A la hora de decidir el modelo y su infraestructura, debemos valorar no solo la precisión técnica, sino también su coste energético. A veces, un modelo más simple y menos preciso puede ser más adecuado si se va a usar en gran escala.”

4.4. Medidas para reducir el impacto ambiental

En este caso, proponemos:

Entrenar un solo modelo general para toda la ciudad, en lugar de uno por barrio.

Usar GPUs de bajo consumo o entrenar en horario valle.

Automatizar el reentrenamiento solo si hay cambios relevantes en los datos.

Documentar el consumo estimado en cada fase para decidir con criterio.

Frase modelo reflexiva para alumnos:

“He optado por reducir el número de reentrenamientos para minimizar el impacto ambiental, y solo actualizo el modelo cuando los datos muestran un cambio significativo en los patrones.”

4.5. Nota de uso como plantilla

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Para cualquier otro reto, el estudiante debe:

Indicar qué infraestructura necesita (local, nube, GPU...).

Justificar si puede entrenar el modelo sin HPC o si lo necesita.

Estimar de forma aproximada el impacto energético (por tiempo de entrenamiento o número de modelos).

Proponer medidas para hacerlo más sostenible.

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Bloque 5: Estimaciones energéticas y comparación con una alternativa ligera

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



5.1. ¿Cuánto consume entrenar este modelo?

El modelo elegido (LSTM) requiere un entrenamiento intensivo, especialmente si usamos múltiples años de datos y varias zonas urbanas.

Supuestos de consumo:

Entrenamiento durante 4 horas en una GPU de 300 W

Se realizan 10 sesiones (para ajustar parámetros y repetir pruebas)

Se entrena un modelo para **10 barrios distintos**

Cálculo:

$4 \text{ horas} \times 300 \text{ W} = 1,2 \text{ kWh}$ por sesión

$1,2 \text{ kWh} \times 10 \text{ sesiones} \times 10 \text{ barrios} = \mathbf{120 \text{ kWh}}$

¿Qué significa esto?

$120 \text{ kWh} \approx$ consumo eléctrico mensual de un hogar eficiente

Equivalente a cargar un coche eléctrico unos 600 km

Aunque parezca asumible, en grandes despliegues o proyectos urbanos reales, este tipo de consumo se multiplica y debe tenerse en cuenta

5.2. ¿Y si se usa un modelo más sencillo?

Una alternativa a las redes neuronales complejas es usar modelos **estadísticos clásicos**, como base para una solución más ligera y fácil de interpretar.

Nota didáctica:

Un modelo como **ARIMA** (AutoRegressive Integrated Moving Average) se usa para predecir valores futuros a partir de datos anteriores, cuando estos siguen un patrón regular en el tiempo.

Aunque no necesitas dominarlo, debes saber que:

Funciona bien cuando los datos son estables y tienen estacionalidad (como consumo horario diario).

No necesita GPU ni mucho entrenamiento.

Es más explicable: se puede entender cómo llega a la predicción.

Estimación orientativa de consumo (estimación razonable):

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



$0,1 \text{ kWh por entrenamiento} \times 10 \text{ sesiones} \times 10 \text{ barrios} = 1 \text{ kWh}$

Nota sobre esta estimación:

Este valor no es una medición real, sino una suposición razonable.

Se asume que un entrenamiento de ARIMA podría hacerse en un portátil o PC convencional que consuma unos 100 W trabajando durante 1 hora.

Este tipo de estimación sirve para comparar el consumo de modelos sencillos con otros más pesados como LSTM, y no necesita conocimientos técnicos avanzados. Lo importante es que sepas razonar cuándo tiene sentido usar una opción más eficiente.

Comparativa rápida:

LSTM: 120 kWh

ARIMA: 1 kWh

La red neuronal consume unas **120 veces más energía**

Frase modelo para alumnos:

“Una alternativa más ligera como ARIMA permitiría ahorrar una gran cantidad de energía. Aunque perderíamos algo de capacidad para detectar patrones complejos, el modelo sería más sostenible y comprensible.”

5.3. ¿Vale la pena el coste energético?

Modelo	Precisión esperada	Adaptabilidad	Consumo energético	Facilidad de explicar
ARIMA	Media	Limitada	Muy bajo	Alta
LSTM	Alta	Alta	Elevado	Baja

La decisión depende del problema específico y de los valores que priorices:

¿Necesitas mucha precisión? → LSTM

¿Te interesa la sostenibilidad, rapidez y simplicidad? → ARIMA

5.4. Decisión final justificada

En este ejemplo, elegimos **LSTM** porque:

El consumo eléctrico tiene muchas variables externas (clima, movilidad, eventos)

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Queremos detectar patrones no triviales

El objetivo es mostrar cómo usar IA avanzada en un contexto urbano

Sin embargo, reconocemos que para algunos contextos o escalas más modestas, podría preferirse una alternativa como ARIMA.

Frase modelo para alumnos:

“He elegido LSTM por su capacidad para trabajar con múltiples variables y aprender patrones complejos. Aun así, si el proyecto tuviera limitaciones energéticas o se necesitara una solución rápida y fácil de interpretar, consideraría modelos como ARIMA.”

5.5. Nota de uso como plantilla

Para cualquier otro reto, el estudiante debe:

Estimar razonablemente el coste computacional de su modelo

Compararlo con una opción más sencilla (aunque no sepa usarla en detalle)

Justificar su elección en función de precisión, sostenibilidad, explicabilidad y contexto de uso

Comentario ético final:

“Un buen profesional no solo elige el modelo más potente, sino el más adecuado para el problema, los datos y los valores del entorno en el que se aplicará.”

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Universitat d'Alacant
Universidad de Alicante

Bloque 6: Reflexión ética y profesional final sobre decisiones tomadas

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



6.1. ¿Por qué es importante esta reflexión?

En un proyecto real, las decisiones técnicas tienen consecuencias sociales, económicas y ambientales. Por eso, al finalizar cualquier diseño de sistema inteligente es importante reflexionar sobre:

Qué decisiones se han tomado.

Qué valores se han priorizado al tomar esas decisiones.

Qué se ha ganado y qué se ha sacrificado.

Qué se haría de forma distinta si el contexto cambiara.

Esta reflexión no solo demuestra madurez técnica, sino también responsabilidad profesional.

Frase modelo:

“No basta con que un modelo funcione. También debe ser justificable, comprensible, eficiente y respetuoso con su entorno.”

6.2. Reflexión sobre las decisiones técnicas

Modelo elegido (LSTM):

Tiene la capacidad de aprender patrones complejos a partir de series temporales y de combinar múltiples variables externas, como clima o movilidad.

Requiere muchos datos históricos de buena calidad para funcionar bien, lo que puede ser un obstáculo en algunos contextos.

Necesita una infraestructura de computación relativamente potente para entrenarse, y consume más energía que otros modelos más simples.

Su funcionamiento interno es más difícil de explicar, lo que puede dificultar su uso en entornos donde la transparencia es esencial.

Alternativas consideradas (por ejemplo, ARIMA):

Se entrenan de forma rápida en ordenadores convencionales y su consumo energético es muy bajo.

Tienen un comportamiento predecible y son fáciles de explicar, por lo que pueden ser útiles en proyectos públicos o institucionales donde se requiera transparencia.

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



Su precisión puede ser inferior, especialmente cuando los patrones de los datos no son regulares o hay múltiples variables influyentes.

Infraestructura de HPC:

Es necesaria para poder entrenar el modelo LSTM de forma eficaz, sobre todo si se desea aplicarlo a varios barrios o zonas con muchos datos.

Puede tener un impacto ambiental significativo si no se toman medidas de optimización.

Se propusieron medidas como usar modelos generales, reducir el número de reentrenamientos y utilizar recursos energéticos eficientes para compensar ese impacto.

Frase modelo para alumnos:

“Aunque he elegido un modelo que requiere más recursos, considero que sus ventajas en precisión y adaptabilidad lo justifican en este caso. Sin embargo, reconozco que en otros contextos, una solución más simple habría sido más adecuada.”

6.3. Reflexión sobre los valores implicados

Cada decisión técnica refleja valores. A continuación, se muestra cómo las decisiones tomadas en este ejemplo responden a distintas prioridades:

Decisión tomada	Valor priorizado
Trabajar con datos agregados	Protección de la privacidad individual
Usar una única red para toda la ciudad	Eficiencia computacional y sostenibilidad
Elegir LSTM como modelo principal	Precisión y capacidad de adaptación
Comparar con un modelo más simple	Responsabilidad profesional y transparencia

Frase modelo para alumnos:

“He intentado equilibrar precisión técnica con sostenibilidad y privacidad, eligiendo decisiones que me parecen justificables desde un punto de vista ético y realista.”

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



6.4. ¿Qué harías distinto si el contexto cambiara?

Es importante mostrar que el sistema no es rígido, sino que podría adaptarse si cambian las condiciones. Por ejemplo:

- Si el sistema tuviera que instalarse en un entorno con pocos recursos, podría sustituirse LSTM por un modelo más ligero y rápido de entrenar.
- Si no hubiera datos suficientes o de buena calidad, podría rediseñarse el sistema para que trabaje con reglas sencillas en lugar de modelos predictivos.
- Si se necesitara que cualquier técnico municipal pudiera entender cómo funciona el sistema, se optaría por modelos más explicables, aunque se perdiera algo de precisión.

Frase modelo para alumnos:

“Si el entorno de aplicación cambiara, ajustaría mi propuesta para mantener el equilibrio entre precisión, coste y sostenibilidad.”

6.5. Nota de uso como plantilla

Para cualquier otro reto, el estudiante debe:

- Resumir las decisiones técnicas que ha tomado y los motivos.
- Explicar qué valores se han tenido en cuenta (por ejemplo, privacidad, sostenibilidad, transparencia).
- Reconocer los límites del sistema propuesto.
- Proponer cómo se podría adaptar el sistema a otros contextos más exigentes o más limitados.

Reflexión final:

“Diseñar con responsabilidad no significa hacerlo perfecto, sino ser consciente de lo que se está haciendo, por qué se hace así, y qué alternativas habría si las condiciones cambiaran.”



Universitat d'Alacant
Universidad de Alicante

Bloque 7: Guía de adaptación, entrega, evaluación y justificación académica

(Aplicación del ejemplo a otros retos + indicaciones finales para el alumno)

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



7.1. Guía para adaptar este ejemplo a otros retos urbanos

El alumnado puede elegir uno de los retos propuestos (por ejemplo: predicción de tráfico, residuos, ocupación de espacios públicos...) y debe estructurar su solución siguiendo los **7 bloques explicados en la plantilla**, adaptando el contenido al nuevo contexto.

Importante: no se espera que todos usen modelos complejos. Se valorará más la justificación razonada de cada decisión que el nivel técnico del modelo usado.

¿Qué debe mantener de la estructura?

Bloque	Qué debe adaptar el alumno
1. Introducción	Definir el nuevo reto elegido y explicar su relevancia social y técnica.
2. Datos	Especificar qué datos usará, de dónde los sacará y cómo tratará los riesgos éticos.
3. Modelo de IA	Comparar al menos dos modelos y justificar el elegido.
4. Infraestructura HPC	Explicar qué recursos usará y cómo limitar el impacto ambiental.
5. Comparación de modelos	Evaluar si un modelo más simple habría sido suficiente.
6. Reflexión ética	Señalar qué valores ha priorizado (privacidad, eficiencia, transparencia...).
7. Comentario final	Proponer adaptaciones posibles a otros contextos o escenarios.

Asignatura. Computación de alto rendimiento (CAR)

Profesor. Ricardo Moreno Rodríguez



7.2. Justificación de los contenidos trabajados (según el CENAE del módulo)

Esta práctica está diseñada para aplicar de forma integrada varios de los contenidos y competencias del módulo de **Computación de Alto Rendimiento**, en especial los siguientes:

Contenidos conceptuales desarrollados:

- Aplicación práctica de la **computación de altas prestaciones** a un problema de IA urbana.
- Evaluación de la **eficiencia energética** en el uso de algoritmos de predicción.
- Toma de decisiones sobre **infraestructuras HPC** (local, distribuida o en la nube).
- Reflexión crítica sobre los **retos actuales en CAR**: ética, sostenibilidad, impacto social.
- Uso de modelos que implican diferentes niveles de consumo, escalabilidad y transparencia.

Competencias trabajadas:

- **CE15** – Selección de arquitecturas y sistemas de computación paralela para resolver problemas complejos.
- **CG1, CG3, CG8** – Diseño y razonamiento crítico de soluciones HPC para IA, teniendo en cuenta criterios éticos y sostenibles.
- **CT02** – Redacción clara y argumentada del informe técnico, dirigida tanto a expertos como a no especialistas.
- **CB2** – Aplicación del conocimiento adquirido en contextos reales y resolución de problemas complejos de forma autónoma.