INTRODUCCIÓN A LA PROGRAMACIÓN PARALELA CON OPENMP (PARTE 2) S1

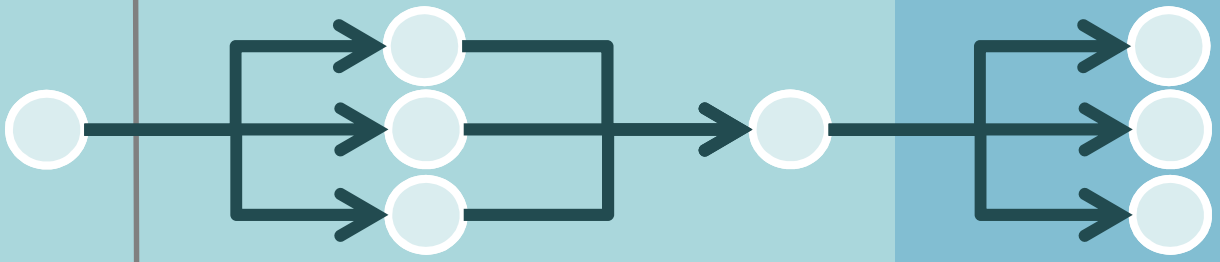

Computación de alto rendimiento

Índice

Introducción a la Optimización en Programación Paralela

Índice

1. Introducción a la Optimización en Programación Paralela

1.1 ¿Por qué optimizar código paralelo?

- **Sobrecarga por sincronización:** Tiempo extra que se pierde esperando en barreras o bloqueos.
- **Contención de recursos:** Accesos concurrentes a memoria compartida pueden ralentizar la ejecución.
- **Desbalanceo de carga:** Si algunos hilos tienen más trabajo que otros, se generan cuellos de botella.
- **Overhead de creación de hilos:** En algunos casos, crear demasiados hilos puede ser contraproducente.

1. Introducción a la Optimización en Programación Paralela

1.2 Principios fundamentales de optimización:

- Minimizar secciones críticas y sincronizaciones.
- Reducir el número de accesos a memoria compartida.
- Balancear la carga entre hilos.
- Evitar trabajo redundante.

Sincronización y Gestión de Hilos en OpenMP

Índice

2. Sincronización y Gestión de Hilos en OpenMP

2.1 Condiciones de carrera y sincronización

- Las condiciones de carrera ocurren cuando múltiples hilos acceden y modifican una variable compartida sin la debida sincronización
- Generan resultados impredecibles.

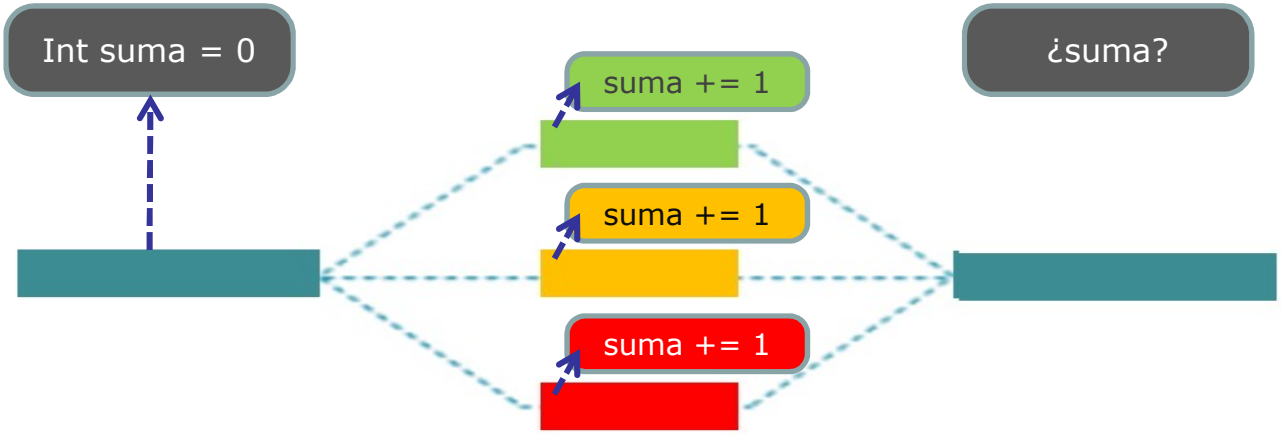

2. Sincronización y Gestión de Hilos en OpenMP

2.2 Directivas de sincronización: critical, atomic y barrier

- **critical**: Protege secciones críticas complejas.
- **atomic**: Más eficiente para operaciones simples.
- **barrier**: Sincroniza todos los hilos en un punto específico.

2. Sincronización y Gestión de Hilos en OpenMP

Critical:

- Protege secciones críticas complejas.
- Garantiza que solo un hilo a la vez ejecute el bloque de código protegido.
- Ventaja: Seguro para operaciones complejas.
- Desventaja: Introduce sobrecarga significativa al hacer que los hilos esperen su turno.

```
#pragma omp critical
{
   contador += 1;
}
```

2. Sincronización y Gestión de Hilos en OpenMP

atomic:

- Protege operaciones simples sobre variables compartidas (sumas, incrementos, etc.).
- Ventaja: Más eficiente que critical para operaciones simples.
- Desventaja: No admite operaciones complejas o múltiples líneas.

```
#pragma omp atomic
contador += 1;
```

2. Sincronización y Gestión de Hilos en OpenMP

barrier:

- Fuerza a todos los hilos a detenerse en un punto hasta que todos hayan alcanzado esa barrera.
- Uso: Sincronizar distintas fases de ejecución.

```
#pragma omp barrier
```

2. Sincronización y Gestión de Hilos en OpenMP

2.3 Comparación entre atomic y critical

- Veamos dos escenarios en los que utilizaremos una de las dos opciones (atomic y crítical)
- En ambos escenarios varios hilos están incrementando un contador global.
- Queremos evitar condiciones de carrera, pero también optimizar el rendimiento.

2. Sincronización y Gestión de Hilos en OpenMP

2.3 Comparación entre atomic y critical

- Opción 1 – Uso de critical:

```
#include <stdio.h>
#include <omp.h>
int main() {
   int contador = 0;
   #pragma omp parallel for
   for (int i = 0; i < 1000000; i++) {
      #pragma omp critical
      {
         contador += 1;
      }
   }
   printf("Contador final: %d\n", contador);
   return 0;
}
```

Resultado correcto, pero **ineficiente** debido a que solo un hilo puede acceder a la sección crítica a la vez.

2. Sincronización y Gestión de Hilos en OpenMP

2.3 Comparación entre atomic y critical

- Opción 2: Uso de atomic

```
#include <stdio.h>
#include <omp.h>
int main() {
    int contador = 0;
    #pragma omp parallel for
    for (int i = 0; i < 1000000; i++) {
        #pragma omp atomic
        contador += 1;  // Operación protegida de forma más eficiente
    }
    printf("Contador final: %d\n", contador);
    return 0;
}
```

Resultado correcto y **más eficiente que critical**.

¿Por qué?

- atomic protege operaciones simples como incrementos y es menos costoso en términos de sincronización.
- Evita la sobrecarga del bloqueo completo que introduce critical.

2. Sincronización y Gestión de Hilos en OpenMP

2.3 Comparación entre atomic y critical

- ¿Cuándo usar critical sobre atomic?
- Recomendamos usar **atomic** para **operaciones simples** sobre variables compartidas (suma, resta, multiplicación).
- Recomendamos usar **critical** cuando la operación involucra **múltiples líneas o es más compleja (por ejemplo, actualizar múltiples variables o** escribir en un archivo).

2. Sincronización y Gestión de Hilos en OpenMP

2.4 Uso de reduction para sincronización segura

- Cada hilo obtiene su propia copia privada de la variable.

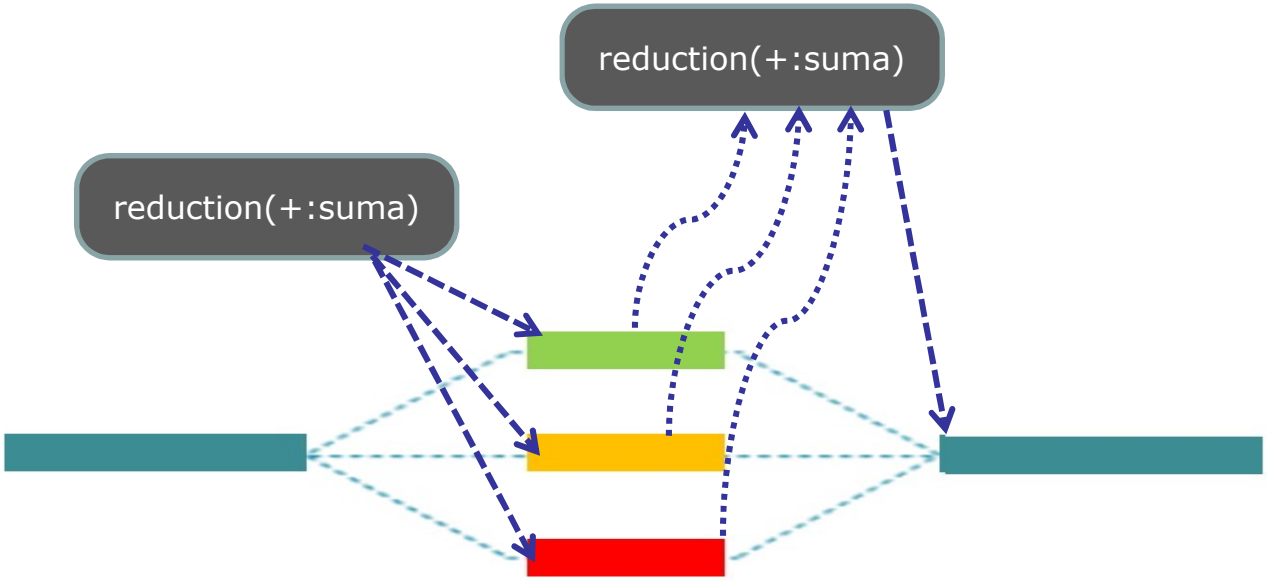

2. Sincronización y Gestión de Hilos en OpenMP

2.4 Uso de reduction para sincronización segura

- La cláusula reduction permite acumular resultados de manera segura evitando condiciones de carrera
- Es más eficiente que critical o atomic para operaciones acumulativas.
- Al finalizar la región paralela, los resultados se combinan utilizando el operador especificado.

2. Sincronización y Gestión de Hilos en OpenMP

2.4 Uso de reduction para sincronización segura

- Ejemplo de suma paralela con reduction:

```
#include <stdio.h>
#include <omp.h>

int main() {
    int N = 1000000;
    long long suma = 0;

    #pragma omp parallel for reduction(+:suma)
    for (int i = 1; i <= N; i++) {
        suma += i;
    }

    printf("Suma total: %lld\n", suma);
    return 0;
}
```

2. Sincronización y Gestión de Hilos en OpenMP

2.4 Uso de reduction para sincronización segura

- Como podemos ver en el código.
  - Cada hilo tiene su propia copia de suma para evitar interferencias.
  - Al finalizar el bucle, OpenMP combina los resultados.
  - Este enfoque elimina condiciones de carrera y es más eficiente que usar atomic o critical (los veremos a continuación).

2. Sincronización y Gestión de Hilos en OpenMP

2.5 Manejo de excepciones en entornos paralelos

- En entornos paralelos con OpenMP, el manejo de excepciones puede ser complicado
- Múltiples hilos podrían generar errores al mismo tiempo.
- OpenMP no proporciona una estructura formal de manejo de excepciones
- Debemos seguir el uso de buenas prácticas para asegurar una ejecución controlada.

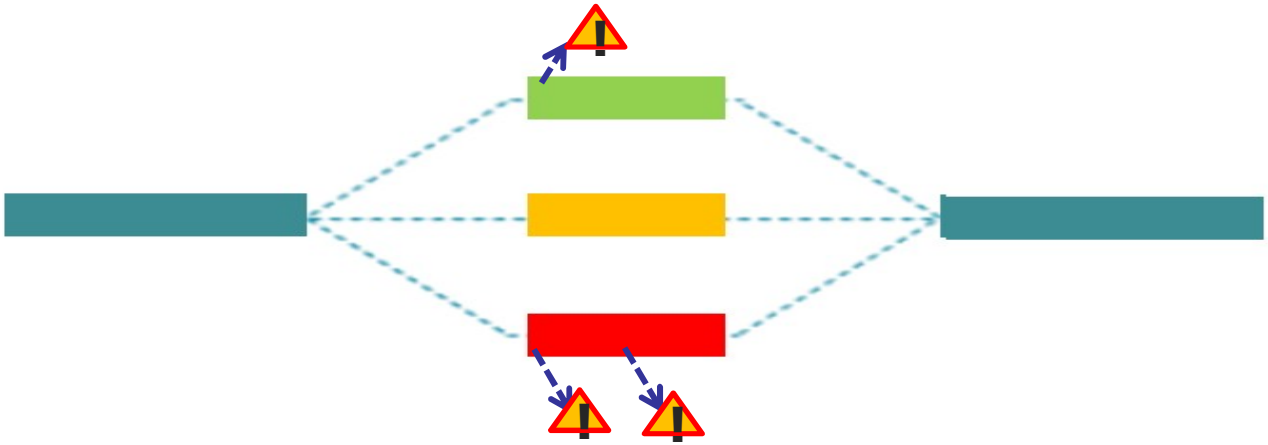

2. Sincronización y Gestión de Hilos en OpenMP

2.5 Manejo de excepciones en entornos paralelos

- Buenas prácticas para manejo de errores:
  - Utilizar **variables compartidas** y banderas (**Flags**) de error para notificar fallos entre hilos.
  - **Proteger secciones críticas** que podrían generar excepciones usando directivas como **critical**.
  - Evitar lanzar excepciones desde dentro de regiones paralelas en C/C++, ya que esto puede generar comportamientos indefinidos.
- Ejemplo:

2. Sincronización y Gestión de Hilos en OpenMP

2.5 Manejo de excepciones en entornos paralelos

- Ejemplo de manejo de errores usando una bandera:

```c
#include <stdio.h>
#include <omp.h>

int main() {
    int error_flag = 0;

    #pragma omp parallel for shared(error_flag)
    for (int i = 0; i < 10; i++) {
        if (i == 5) {  // Simulación de un error
            #pragma omp critical
            {
                printf("Error en el hilo %d en la iteración %d\n", omp_get_thread_num(), i);
                error_flag = 1;
            }
        }
    }

    if (error_flag) {
        printf("Ejecución completada con errores.\n");
    } else {
        printf("Ejecución completada sin errores.\n");
    }

    return 0;
}
```

Balanceo de Carga y Distribución de Trabajo

Índice

3. Balanceo de Carga y Distribución de Trabajo

3.1 Distribución eficiente de carga con schedule()

- Problema del desbalanceo de carga:
  - Si ciertos hilos tienen significativamente **más trabajo que otros**, los hilos más rápidos quedarán ociosos mientras esperan a los más lentos
- Solución:
  - Utilizar **schedule** para que los hilos tomen nuevas tareas cuando terminan.
  - **Reducir** el tamaño del "**chunk**" para mejorar el equilibrio (a costa de mayor overhead de sincronización).

3. Balanceo de Carga y Distribución de Trabajo

3.1 Distribución eficiente de carga con schedule()

static: Cargas uniformes y predecibles.

dynamic: Cargas desbalanceadas o variables.

guided: Cargas pesadas e impredecibles.

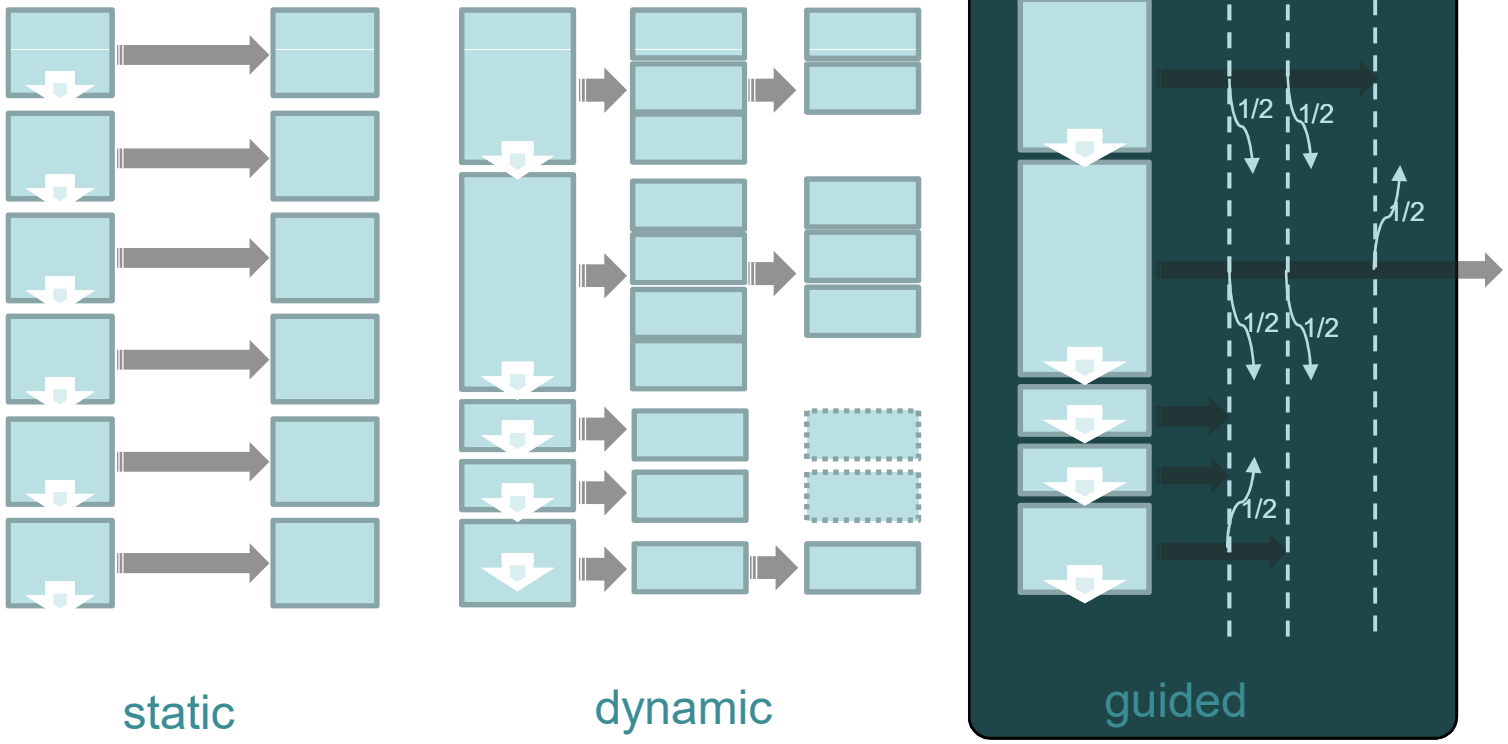

3. Balanceo de Carga y Distribución de Trabajo

3.2 ¿Por qué usar schedule(dynamic)?

- schedule(static) puede provocar un desbalance de carga.
- schedule(dynamic) mejora el equilibrio
- Ejemplo con **schedule(static)**:

```
#include <stdio.h>
#include <omp.h>
#include <unistd.h>

int main() {
    #pragma omp parallel for schedule(static)
    for (int i = 0; i < 8; i++) {
        printf("Hilo %d procesando iteración %d\n", omp_get_thread_num(), i);
        sleep(i % 3);  // Simula tareas con duraciones variables
    }
    return 0;
}
```

- **Problema**:
  - Las tareas más largas ralentizan el hilo al que se asignaron inicialmente, mientras que otros hilos terminan antes y **quedan ociosos**.

3. Balanceo de Carga y Distribución de Trabajo

3.2 ¿Por qué usar schedule(dynamic)?

- Solución: Uso de **schedule(dynamic)**, Ejemplo:

```
#include <stdio.h>
#include <omp.h>
#include <unistd.h>

int main() {
   #pragma omp parallel for schedule(dynamic, 1)
   for (int i = 0; i < 8; i++) {
      printf("Hilo %d procesando iteración %d\n", omp_get_thread_num(), i);
      sleep(i % 3);  // Simula tareas con duraciones variables
   }
   return 0;
}
```

- Ventajas de schedule(dynamic):
  - Los hilos toman nuevas iteraciones dinámicamente al finalizar su trabajo actual.
  - Mejora el balance de carga en escenarios con tareas heterogéneas.
  - Reduce el tiempo total de ejecución.

3. Balanceo de Carga y Distribución de Trabajo

3.3 Paralelización Anidada (Nested Parallelism)

- OpenMP permite la creación de regiones **paralelas** dentro de otras regiones paralelas: **paralelización anidada**
- Aunque está desactivada por defecto, se puede **habilitar** usando la función **omp_set_nested(1)**
- **Ventajas**:
  - Permite explotar **más niveles de paralelismo**, especialmente en aplicaciones complejas.
  - Útil en problemas jerárquicos, como simulaciones multi-escala o algoritmos de matrices bloqueadas.
- **Desventajas**:
  - Puede incrementar la sobrecarga por gestión de hilos.
  - Requiere un buen balanceo de carga para evitar ineficiencias.

3. Balanceo de Carga y Distribución de Trabajo

3.3 Paralelización Anidada (Nested Parallelism)

- Ejemplo de paralelización anidada:

```c
#include <stdio.h>
#include <omp.h>

int main() {
    omp_set_nested(1);  // Habilitar paralelización anidada

    #pragma omp parallel num_threads(2)
    {
        printf("Nivel 1: Hilo %d\n", omp_get_thread_num());

        #pragma omp parallel num_threads(2)
        {
            printf("  Nivel 2: Hilo %d\n", omp_get_thread_num());
        }
    }
    return 0;
}
```

```
Nivel 1: Hilo 0
  Nivel 2: Hilo 0
  Nivel 2: Hilo 1
Nivel 1: Hilo 1
  Nivel 2: Hilo 0
  Nivel 2: Hilo 1
```

Optimización de Accesos a Memoria y Reducción de Datos

Índice

4. Optimización de Accesos a Memoria y Reducción de Datos

4.1 Minimizar accesos a memoria compartida

- El acceso frecuente a memoria compartida por múltiples hilos introduce latencia
- Puede generar **contention**, afectando la eficiencia general
- Ejemplo:

4. Optimización de Accesos a Memoria y Reducción de Datos

4.1 Minimizar accesos a memoria compartida

- Ejemplo con Accesos Frecuentes a Memoria Compartida

```
#include <stdio.h>
#include <omp.h>

int main() {
   int data[10000];
   int suma = 0;

   #pragma omp parallel for
   for (int i = 0; i < 10000; i++) {
      #pragma omp atomic
      suma += data[i];  // Cada iteración accede a memoria compartida
   }

   printf("Suma total: %d\n", suma);
   return 0;
}
```

- Problema:
  - Cada hilo lee y actualiza la memoria compartida (suma) en cada iteración, generando cuello de botella.

4. Optimización de Accesos a Memoria y Reducción de Datos

4.1 Minimizar accesos a memoria compartida

- Solución: Uso de **Variables Locales** por Hilo:

```
#include <stdio.h>
#include <omp.h>

int main() {
   int data[10000];
   int suma = 0;

   // Utiliza reduction para evitar accesos frecuentes a suma
   #pragma omp parallel for reduction(+:suma)
   for (int i = 0; i < 10000; i++) {
      suma += data[i];  // Acumulación local por hilo
   }

   printf("Suma total: %d\n", suma);
   return 0;
}
```

- Beneficios:
  - Cada hilo acumula la suma en su propia variable local.
  - Los resultados se combinan al final, minimizando accesos a memoria compartida.
- **Resultado**: Mejora significativa del rendimiento.

4. Optimización de Accesos a Memoria y Reducción de Datos

4.1 Minimizar accesos a memoria compartida

Consejos Generales para Reducir Accesos a Memoria:

1. Usar **variables locales** dentro de regiones paralelas siempre que sea posible.
2. Agrupar lecturas/escrituras para minimizar los accesos dispersos.
3. Evitar variables compartidas innecesarias.
4. Usar técnicas de **reducción** para consolidar resultados de manera eficiente.

4. Optimización de Accesos a Memoria y Reducción de Datos

4.2 Alineación de datos y uso eficiente de cachés

- La forma en la que accedemos a memoria también afecta al rendimiento de aplicaciones paralelas
  - Mejor: usar accesos a memorias locales (caché)
  - Alinear estructuras de datos a los límites de caché para evitar penalizaciones de acceso
  - Evitar falsas comparticiones: varios hilos acceden a diferentes variables almacenadas en la misma línea de caché, generando conflictos innecesarios.

4. Optimización de Accesos a Memoria y Reducción de Datos

4.2 Alineación de datos y uso eficiente de cachés

- Ejemplo de falsa compartición:

```c
#include <stdio.h>
#include <omp.h>

#define N 1000000

typedef struct {
    double x;
    double y;  // Sin separación, puede causar falsa compartición
} Point;

int main() {
    Point points[4];

    #pragma omp parallel for
    for (int i = 0; i < 4; i++) {
        for (int j = 0; j < N; j++) {
            points[i].x += j * 0.1;
        }
    }

    return 0;
}
```

4. Optimización de Accesos a Memoria y Reducción de Datos

4.2 Alineación de datos y uso eficiente de cachés

- **Solución**: Añadir relleno para evitar que dos variables usadas por distintos hilos compartan la misma línea de caché:

```
typedef struct {
    double x;
    char padding[64];  // Relleno para evitar falsa compartición
    double y;
} Point;
```

4. Optimización de Accesos a Memoria y Reducción de Datos

4.3 Variables privadas: private, firstprivate, lastprivate

- **private**: Cada hilo tiene su propia copia no inicializada.
- **firstprivate**: Inicializa las copias privadas con el valor original.
- **lastprivate**: Copia el valor de la última iteración al ámbito global.
- Ejemplo:

4. Optimización de Accesos a Memoria y Reducción de Datos

4.3 Variables privadas: private, firstprivate, lastprivate

- Ejemplo:

```
#include <stdio.h>
#include <omp.h>

int main() {
   int x = 10;

   #pragma omp parallel for private(x) firstprivate(x) lastprivate(x)
   for (int i = 0; i < 5; i++) {
      x += i;
      printf("Hilo %d - Valor de x: %d\n", omp_get_thread_num(), x);
   }

   printf("Valor final de x después del bucle: %d\n", x);
   return 0;
}
```

- Resultado esperado:
  - Cada hilo trabaja con su propia copia de x.
  - La última iteración actualiza el valor global de x.

4. Optimización de Accesos a Memoria y Reducción de Datos

4.4 Inicialización con la clausula copyin

- **inicializa** las variables declaradas como **threadprivate** en cada hilo con el valor de la variable global antes de entrar en una región paralela
- ¿Cuándo usar copyin?
  - Cuando se tiene una **variable global** declarada como **threadprivate**.
  - Para asegurar que cada hilo comience con el mismo valor inicial antes de ejecutar la región paralela.
- **Ejemplo básico:**

4. Optimización de Accesos a Memoria y Reducción de Datos

4.4 Inicialización con la clausula copyin

- **Ejemplo básico:**

```
Hilo 0 - Config inicial: 100
Hilo 1 - Config inicial: 100
Hilo 2 - Config inicial: 100
Hilo 3 - Config inicial: 100
```

```c
#include <stdio.h>
#include <omp.h>

// Variable global
int global_config = 42;

// Declarar como threadprivate
#pragma omp threadprivate(global_config)

int main() {
    // Modificar antes de la región paralela
    global_config = 100;

    // Región paralela usando copyin
    #pragma omp parallel copyin(global_config)
    {
        printf("Hilo %d - Config inicial: %d\n", omp_get_thread_num(), global_config);
    }

    return 0;
}
```