

# Introducción

**Ingeniería en Inteligencia Artificial**

**Razonamiento bajo Incertidumbre**

*El tratamiento de la incertidumbre es uno de los campos fundamentales de la inteligencia artificial, pues afecta en mayor o menor medida a todos los demás.*

*En particular, una de las propiedades esenciales de los sistemas expertos, y a la vez una de las más complejas, es el tratamiento de la incertidumbre.*

*Vamos a tomar como ejemplo el campo de la medicina, con el fin de mostrar la importancia del tema.*

# **Fuentes de incertidumbre**

A grandes rasgos, podemos clasificar las fuentes de incertidumbre en tres grupos:

- 1) Deficiencias de la información: incompleta, errónea o imprecisa
- 2) Características del mundo real no determinista
- 3) Deficiencias del modelo: incompleto o inexacto

Algunos ejemplos de fuentes de incertidumbre son:

***Información incompleta.*** Por ejemplo, en medicina, el historial clínico de un paciente no está disponible, y el paciente es incapaz de recordar todos los síntomas que ha experimentado y cómo se ha desarrollado la enfermedad. Además, en otras ocasiones, las limitaciones prácticas impiden contar con todos los medios que deberían estar disponibles, por lo que la información que posee el médico es muy limitada.

***Información errónea.*** En cuanto a la información suministrada por el paciente, puede que éste describa incorrectamente sus síntomas e incluso que trate de mentir deliberadamente. También es posible que el diagnóstico anterior, contenido en la historia clínica, haya sido erróneo. Y tampoco es extraño que las pruebas de laboratorio den falsos positivos y falsos negativos.

***Información imprecisa.*** Siguiendo con la aplicación médica, hay muchos datos en medicina que son difícilmente cuantificables, por ejemplo, los síntomas del dolor o la fatiga.

***Mundo real no determinista.*** A diferencia de las máquinas mecánicas o eléctricas, cuyo funcionamiento se rige por leyes deterministas, cada ser humano es un mundo, en que las leyes generales no siempre resultan aplicables. Muchas veces las mismas causas producen efectos diferentes, sin que haya ninguna explicación aparente.

***Modelo incompleto.*** Por un lado, hay muchos fenómenos cuya causa aún se desconoce. Incluso es frecuente la falta de acuerdo entre los expertos de un mismo campo. Finalmente, aunque toda esta información estuviera disponible, sería imposible, por motivos prácticos, incluirla en un sistema experto.

***Modelo inexacto.*** Todo modelo que trate de cuantificar la incertidumbre, por cualquiera de los métodos que existen, necesita incluir un elevado número de parámetros. Por ejemplo, en el caso de las redes bayesianas, necesitamos especificar todas las probabilidades a priori y condicionales. Sin embargo, una gran parte de esta información no suele estar disponible, por lo que debe ser estimada de forma subjetiva. Es deseable que el método de razonamiento empleado tenga en cuenta las inexactitudes del modelo.

Aunque todas estas fuentes de incertidumbre pueden darse, y de hecho se dan, en cualquier campo como las ciencias naturales, la ingeniería, el derecho o las humanidades, entre otros. El dominio incierto se da muy especialmente en los problemas de reconocimiento del lenguaje natural, tanto hablado como escrito, donde la información implícita, la polisemia, la ambigüedad y la imprecisión, **hacen imprescindible el tratamiento de la incertidumbre.**

En realidad, ésta es una necesidad que no sólo incumbe a los sistemas expertos y a los problemas de lenguaje natural, sino a todas las ramas de la inteligencia artificial, como el aprendizaje, la visión artificial, la robótica, los interfaces inteligentes, la recuperación de información, los juegos complejos (no sólo los juegos de azar, sino también juegos como el ajedrez, donde no se conocen con certeza las preferencias del contrario), etc.

**El tratamiento de la  
incertidumbre es, junto con la  
representación del conocimiento  
y el aprendizaje, uno de los  
problemas fundamentales de la  
inteligencia artificial.**

Motivados por los distintos  
problemas que se han ido  
planteando , se le ha prestado  
mucho atención y han surgido  
muchos métodos.



Los métodos de razonamiento incierto se clasifican en dos grandes grupos: **métodos numéricos y métodos cualitativos.**

Entre los **métodos cualitativos** para el tratamiento de la incertidumbre, destacan los basados en lógicas no monótonas, tales como los modelos de *razonamiento por defecto* (el más conocido es el de Reiter), los sistemas de *suposiciones razonadas* de Doyle y la *teoría de justificaciones* de Cohen y Grinberg. En estos métodos, cuando no hay información suficiente, hacen suposiciones que posteriormente podrán ser corregidas al recibir nueva información. El problema principal es su naturaleza cualitativa. Suelen presentar además problemas de explosión combinatoria. En consecuencia, se estudian más por su importancia teórica (fundamentación de la inteligencia artificial) que por las aplicaciones prácticas a que puedan dar lugar.

Cuando el razonamiento incierto se realiza mediante métodos numéricos suele hablarse de **razonamiento aproximado**.

Los **métodos numéricos** son los que vamos a estudiar al principio del curso y el primero que surgió fue el tratamiento probabilista, propuesto por Bayes y Laplace en el siglo XVIII.

En el siglo XX, aparecen las computadoras y poco después surge la inteligencia artificial. Al principio, los ordenadores estaban muy lejos del denominado “comportamiento inteligente” y solo se centraba en la resolución de problemas simbólicos. Sin embargo, al enfrentarse, por ejemplo, a problemas de diagnóstico médico, era inevitable tener que tratar la incertidumbre y, al principio, la única técnica disponible, era el método probabilista clásico (a veces llamado *Naïve Baye*).

El método probabilista clásico presentaba **dos inconvenientes principales**:

**1) La dificultad de obtener las probabilidades condicionales** necesarias para construir el modelo. La aplicación del teorema de Bayes “en bruto” requería un número exponencial de parámetros por lo que se hacía necesario introducir hipótesis simplificadoras, que eran básicamente dos: la exclusividad de los diagnósticos y la independencia condicional de los hallazgos. Aún así, el número de parámetros seguía siendo relativamente elevado, sobre todo teniendo en cuenta que raramente existían datos a partir de los cuales se pudieran obtener las probabilidades objetivas, por lo que en la mayor parte de los casos se hacían estimaciones subjetivas (poco fiables).

**2) Hipótesis poco verosímiles**, sobre todo la de independencia condicional. Por estos motivos, la mayor parte de los investigadores estaban de acuerdo en que la probabilidad no era un método adecuado para la inteligencia artificial.

Por otro lado, el éxito obtenido por el sistema experto DENDRAL, considerado por muchos como el primer sistema experto, mostró las grandes ventajas de la programación mediante reglas. Sus creadores buscaban un método de computación eficiente que pudiera adaptarse al razonamiento mediante encadenamiento de reglas.

Basado en DENDRAL se desarrolló, una década más tarde, el sistema experto MYCIN que pretendía estudiar enfermedades infecciosas.

Los dos problemas mencionados anteriormente y la incapacidad de los métodos probabilistas para encajar en este esquema llevaron a desarrollar un método propio, consistente en asignar a cada regla un factor de certeza. Este modelo, aunque inspirado lejanamente en el cálculo de probabilidades, a través de la teoría de la confirmación de Carnap, en la práctica no tenía ninguna relación con la teoría de la probabilidad, ni siquiera con su interpretación subjetiva.

El éxito de MYCIN fue muy grande, pues en un campo tan complejo y tan incierto como el de las enfermedades infecciosas, fue capaz de conseguir diagnósticos y recomendaciones terapéuticas al menos tan buenos como los de los mejores expertos de su especialidad.

Sin embargo, los propios creadores del modelo estaban insatisfechos con él, y por ello encargaron a un matemático, J. B. Adams un estudio, el cual demostró que en el método de combinación convergente de reglas había unas hipótesis implícitas tan fuertes como la independencia condicional exigida por el método probabilista, pero más difíciles de justificar.

Cuando los creadores de MYCIN tenían puestos sus ojos en la teoría de Dempster-Shafer como tabla de salvación del modelo de factores de certeza, ocurrió un acontecimiento que cambió completamente el escenario: la aparición de las redes bayesianas, un modelo probabilista inspirado en la causalidad, cuya virtud principal consiste en que lleva asociado un modelo gráfico en que cada nodo representa una variable y cada enlace representa, generalmente, un mecanismo causal.

En paralelo con esta evolución histórica de crisis y resurgimiento de la probabilidad, se desarrolló la *teoría de los conjuntos difusos o lógica difusa*.

La motivación inicial no fue el estudio de la incertidumbre, sino el estudio de la vaguedad, que es algo diferente. Por ejemplo, si sabemos que Juan mide 1'78 m., no podemos decir con rotundidad que es alto, pero tampoco podemos decir que no lo es: se trata de una cuestión de grado; en este caso hay vaguedad intrínseca, pero no hay incertidumbre, con lo que se demuestra que son dos conceptos en principio independientes, aunque existe una cierta relación en el sentido de que recibimos una información imprecisa (luego tenemos una cierta incertidumbre).

La brillante idea de Lofti Zadeh —considerado como el “padre” de la lógica difusa— consiste en permitir que el **grado de pertenencia** sea un número entre 0 y 1.

El punto más débil de la lógica difusa es la carencia de una definición operativa que permita determinar objetivamente el grado de pertenencia.

Es importante señalar que, mientras las redes bayesianas y la lógica difusa son temas de gran actualidad, el método probabilista clásico y el modelo de factores de certeza se consideran temas “muertos” desde el punto de vista de la investigación.

En realidad, el método probabilista clásico es un caso particular de red bayesiana que ayuda a entenderlas mejor ya que se pueden realizar simplificaciones (no son válidas para redes bayesianas generales).

En cuanto a los factores de certeza, Heckerman demostró en 1986, que es imposible construir un modelo coherente de factores de certeza, salvo para casos sumamente simples. Pero, a pesar de sus graves inconsistencias se sigue utilizando en muchos de los sistemas expertos de la actualidad pues la única alternativa que existe para el razonamiento aproximado mediante reglas es la lógica difusa, con la que resulta más difícil construir un modelo al aumentar considerablemente el coste computacional.