

Ejercicio 1: Backpropagation

Jordi Blasco Lozano

Planteamiento

Se considera una red neuronal feedforward con una neurona por capa. La arquitectura es:

$$a^{(0)} = x \longrightarrow (L-2) \longrightarrow (L-1) \longrightarrow (L) = \hat{y}.$$

En cada capa se calcula una preactivación $z^{(l)}$ y una activación $a^{(l)}$.

Datos iniciales

- Entrada: $x = 1$.
- Pesos iniciales: $W^{(L-2)} = 0,32$, $W^{(L-1)} = 0,18$, $W^{(L)} = 0,23$.
- Sesgos iniciales: $b^{(L-2)} = 0$, $b^{(L-1)} = 0$, $b^{(L)} = 0$.
- Tasa de aprendizaje: $\alpha = 0,1$.
- Etiqueta (target): $y = 1$.

Notación y fórmulas

Para cada capa l :

$$\begin{aligned} z^{(l)} &= W^{(l)} a^{(l-1)} + b^{(l)}, \\ a^{(l)} &= \sigma(z^{(l)}). \end{aligned}$$

Se usa la sigmoide:

$$\sigma(t) = \frac{1}{1 + e^{-t}}, \quad \sigma'(t) = \sigma(t)(1 - \sigma(t)).$$

Función de pérdida:

$$L = (\hat{y} - y)^2.$$

Al trabajar con un solo ejemplo, “loss” y “cost” coinciden numéricamente.

1. Apartado 1: Forward pass (cálculo de z , a y \hat{y})

En el forward pass se calculan las activaciones desde la entrada hasta la salida.

Capa $L-2$

$$\begin{aligned} z^{(L-2)} &= W^{(L-2)} x + b^{(L-2)} = 0,32 \cdot 1 + 0 = 0,32, \\ a^{(L-2)} &= \sigma(z^{(L-2)}) = \frac{1}{1 + e^{-0,32}} \approx \frac{1}{1 + 0,7261} \approx 0,5793. \end{aligned}$$

Capa $L - 1$

$$z^{(L-1)} = W^{(L-1)} a^{(L-2)} + b^{(L-1)} = 0,18 \cdot 0,5793 + 0 \approx 0,1043,$$

$$a^{(L-1)} = \sigma(z^{(L-1)}) = \frac{1}{1 + e^{-0,1043}} \approx \frac{1}{1 + 0,9009} \approx 0,5260.$$

Capa de salida L

$$z^{(L)} = W^{(L)} a^{(L-1)} + b^{(L)} = 0,23 \cdot 0,5260 + 0 \approx 0,1210,$$

$$\hat{y} = a^{(L)} = \sigma(z^{(L)}) = \frac{1}{1 + e^{-0,1210}} \approx \frac{1}{1 + 0,8860} \approx 0,5302.$$

Pérdida (loss)

$$L = (\hat{y} - y)^2 = (0,5302 - 1)^2 = (-0,4698)^2 \approx 0,2207.$$

Resumen del forward pass

Capa	$z^{(l)}$	$a^{(l)}$	Comentario
$L - 2$	0,32	0,5793	$a^{(0)} = x = 1$
$L - 1$	0,1043	0,5260	$\sigma(z)$
L	0,1210	$\hat{y} = 0,5302$	salida

2. Apartado 2: Backward pass (gradientes y actualización)

El objetivo es actualizar $W^{(L)}$ y $b^{(L-1)}$ mediante descenso por gradiente.

Mapa de dependencias (para justificar la regla de la cadena)

$$W^{(L)} \rightarrow z^{(L)} \rightarrow \hat{y} \rightarrow L, \quad b^{(L-1)} \rightarrow z^{(L-1)} \rightarrow a^{(L-1)} \rightarrow z^{(L)} \rightarrow \hat{y} \rightarrow L.$$

Para simplificar, definimos el “error” (delta) por capa:

$$\delta^{(l)} := \frac{\partial L}{\partial z^{(l)}}.$$

Los gradientes se calculan con los parámetros del forward actual (antes de aplicar la actualización).

Capa de salida L

1) Derivada de la pérdida respecto a la salida

$$\frac{\partial L}{\partial \hat{y}} = \frac{\partial}{\partial \hat{y}} (\hat{y} - y)^2 = 2(\hat{y} - y) = 2(0,5302 - 1) \approx -0,9396.$$

2) Delta de la capa de salida

$$\begin{aligned} \delta^{(L)} &= \frac{\partial L}{\partial z^{(L)}} = \frac{\partial L}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial z^{(L)}} = \frac{\partial L}{\partial \hat{y}} \sigma'(z^{(L)}) \\ &= (-0,9396) (\hat{y}(1 - \hat{y})) = (-0,9396) (0,5302 \cdot 0,4698) \approx (-0,9396) \cdot 0,2491 \approx -0,2340. \end{aligned}$$

3) Gradiente respecto a $W^{(L)}$

Como $z^{(L)} = W^{(L)}a^{(L-1)} + b^{(L)}$, se tiene $\frac{\partial z^{(L)}}{\partial W^{(L)}} = a^{(L-1)}$. Por tanto:

$$\frac{\partial L}{\partial W^{(L)}} = \frac{\partial L}{\partial z^{(L)}} \frac{\partial z^{(L)}}{\partial W^{(L)}} = \delta^{(L)} a^{(L-1)} \approx (-0,2340) \cdot 0,5260 \approx -0,1231.$$

4) Actualización de $W^{(L)}$

$$W_{\text{nuevo}}^{(L)} = W^{(L)} - \alpha \frac{\partial L}{\partial W^{(L)}} = 0,23 - 0,1 \cdot (-0,1231) \approx 0,2423.$$

Capa $L - 1$ (para actualizar $b^{(L-1)}$)

5) Propagación del delta a la capa anterior

$$\delta^{(L-1)} = \frac{\partial L}{\partial z^{(L-1)}} = \underbrace{\frac{\partial L}{\partial z^{(L)}}}_{\delta^{(L)}} \underbrace{\frac{\partial z^{(L)}}{\partial a^{(L-1)}}}_{W^{(L)}} \underbrace{\frac{\partial a^{(L-1)}}{\partial z^{(L-1)}}}_{\sigma'(z^{(L-1)})}.$$

Sustituyendo valores del forward (con $W^{(L)} = 0,23$ antes de actualizar):

$$\begin{aligned} \delta^{(L-1)} &= \delta^{(L)} W^{(L)} \sigma'(z^{(L-1)}) \\ &\approx (-0,2340) \cdot 0,23 \cdot (a^{(L-1)}(1 - a^{(L-1)})) \\ &\approx (-0,2340) \cdot 0,23 \cdot (0,5260 \cdot 0,4740) \\ &\approx (-0,2340) \cdot 0,23 \cdot 0,2493 \approx -0,0134. \end{aligned}$$

6) Gradiente y actualización de $b^{(L-1)}$

Como $z^{(L-1)} = W^{(L-1)}a^{(L-2)} + b^{(L-1)}$, se cumple $\frac{\partial z^{(L-1)}}{\partial b^{(L-1)}} = 1$, y por tanto:

$$\frac{\partial L}{\partial b^{(L-1)}} = \delta^{(L-1)} \approx -0,0134.$$

La actualización queda:

$$b_{\text{nuevo}}^{(L-1)} = b^{(L-1)} - \alpha \frac{\partial L}{\partial b^{(L-1)}} = 0 - 0,1 \cdot (-0,0134) \approx 0,00134.$$

Resumen final

Magnitud	Valor
\hat{y}	0,5302
$L = (\hat{y} - y)^2$	0,2207
$\frac{\partial L}{\partial W^{(L)}}$	-0,1231
$W_{\text{nuevo}}^{(L)}$	0,2423
$\frac{\partial L}{\partial b^{(L-1)}}$	-0,0134
$b_{\text{nuevo}}^{(L-1)}$	0,00134